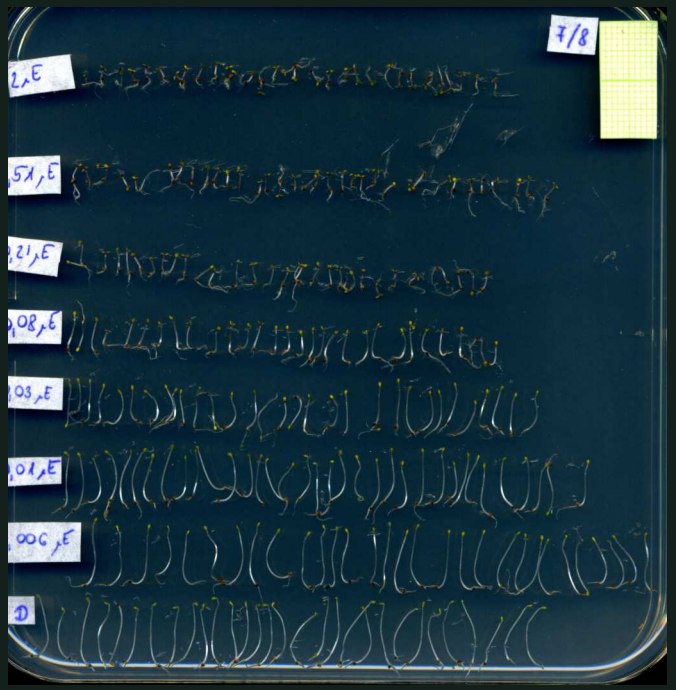
UNIVERSIDAD EAFIT · INGENIERÍA AGRONÓMICA · 2026

Segmentación de plántulas con Naive Bayes

Evaluación de segmentación supervisada RGB: ¿qué tan lejos llega un método simple frente al aprendizaje profundo?



AUTORES

Santiago Knobelsdorf Velasquez
Jerónimo Echeverri Mejía
Agustín González Mejía

ASIGNATURA Y PROFESORA

Big Data y Bioinformática
Luisa Fernanda Gómez Ossa

EL PROYECTO DE UN VISTAZO

Qué, cómo y para qué

01 · EL PROBLEMA

¿Qué?

Segmentar por color, píxel a píxel, plántulas de tres especies en tres clases: fondo, otras estructuras e hipocótilo.

02 · EL MÉTODO

¿Cómo?

Un clasificador Gaussian Naive Bayes por especie, entrenado con unos 250 píxeles RGB anotados a mano y evaluado contra las máscaras de referencia.

03 · EL PROPÓSITO

¿Para qué?

Medir si una alternativa ligera, solo en Python y sin U-Net ni ImageJ, sirve para el fenotipado vegetal, y conocer dónde falla.

¿QUÉ? · PREGUNTA DE INVESTIGACIÓN

¿En qué medida un modelo Naive Bayes que solo usa el color RGB logra identificar y delimitar las estructuras de plántulas de tres especies, frente a las máscaras de referencia?

El contexto

El fenotipado vegetal mide rasgos morfológicos, como la longitud del hipocótilo. Medirlos a mano en imágenes no escala a poblaciones grandes.

La apuesta

Probar un camino de menor complejidad computacional: clasificar cada píxel con probabilidades sobre sus tres canales de color, solo en Python.

¿QUÉ? · ALCANCE

Objetivos del estudio

OBJETIVO GENERAL

Evaluar el desempeño de un modelo de segmentación supervisada basado en Naive Bayes y color RGB, implementado en Python, para identificar y delimitar las estructuras de plántulas de tres especies, comparándolo con las máscaras de referencia.

ESPECÍFICO 1 · EL CÓMO

Implementar en Python un clasificador Naive Bayes sobre los canales RGB, ajustado de forma independiente para cada especie.

ESPECÍFICO 2 · EL PARA QUÉ

Comparar las máscaras obtenidas con las de referencia mediante métricas objetivas, para determinar el desempeño en las tres especies.

¿QUÉ? · LOS DATOS

Plant Segmentation: tres especies, tres clases

Dataset de Kaggle publicado por Tivadar Danka: fotografías RGB de alta resolución de *Arabidopsis thaliana*, *Sinapis alba* y *Brachypodium distachyon*, con su máscara de referencia. Las máscaras sirven solo para evaluar, nunca para entrenar.

CLASE 0

Fondo

Sustrato de crecimiento y sombras.

CLASE 1

Otras estructuras

Cotiledones, hojas y raíces secundarias.

CLASE 2

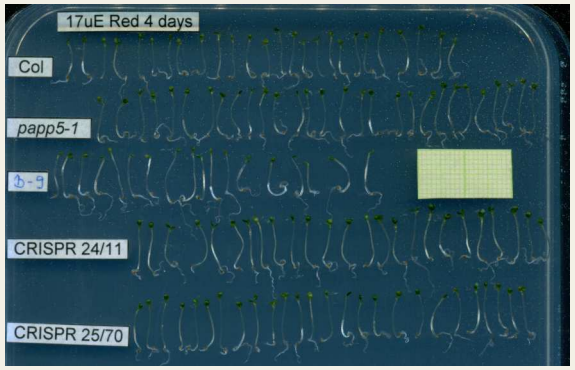
Hipocótilo / coleóptilo

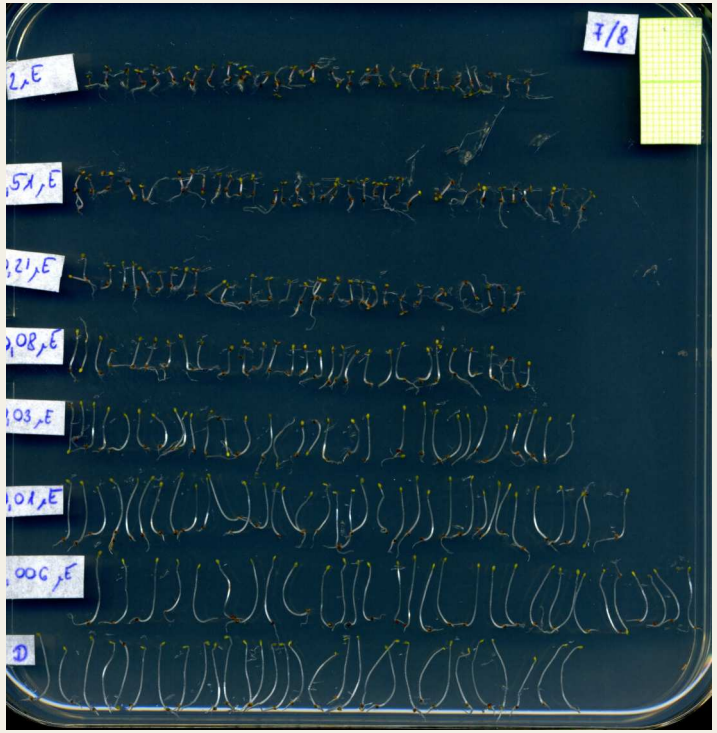
El órgano objetivo del fenotipado.

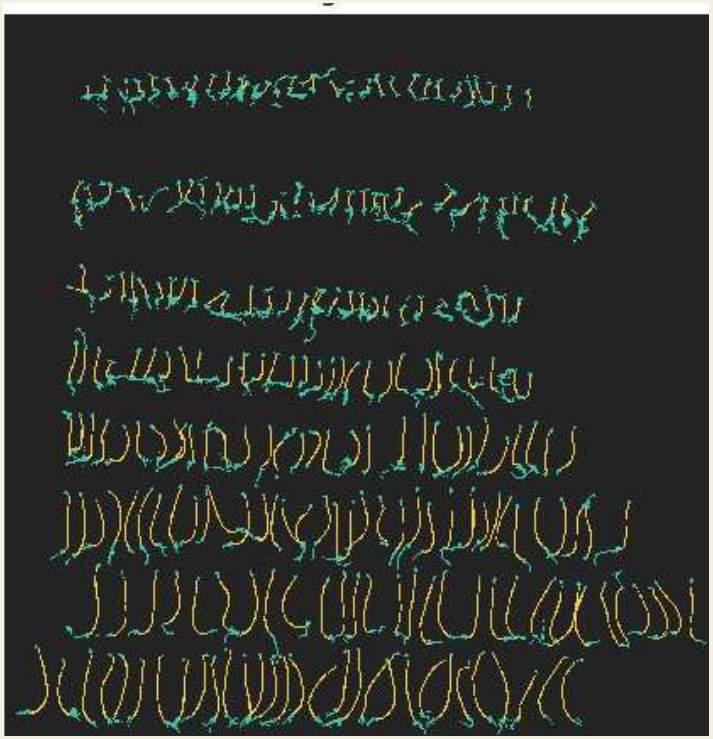
¿QUÉ? · LOS DATOS

Arabidopsis Thaliana:





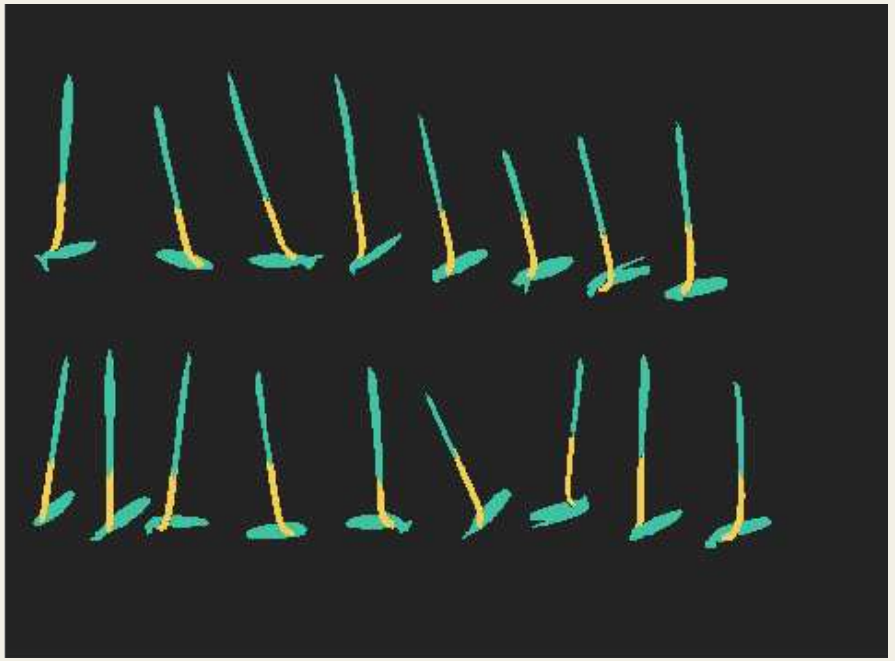




¿QUÉ? · LOS DATOS

Brachypodium:

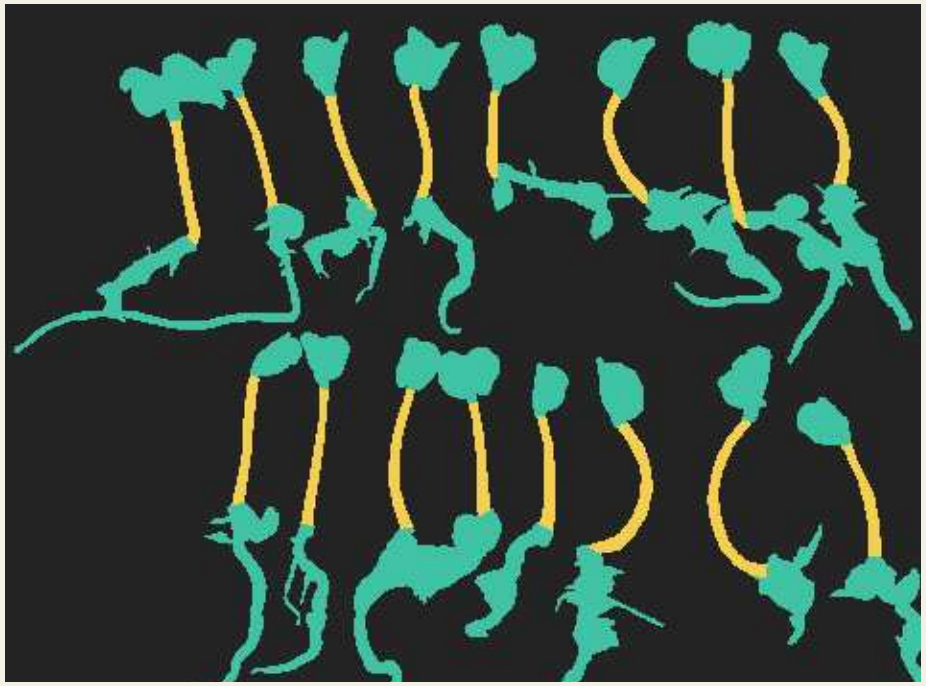




¿QUÉ? · LOS DATOS

Sinapis:





¿QUÉ? · EL PUNTO DE PARTIDA

Dobos et al. (2019) frente a una alternativa ligera

ESTUDIO DE REFERENCIA · U-NET

Red neuronal convolucional profunda, con Fiji/ImageJ para anotar, segmentar y esqueletizar. Sus mediciones del hipocótilo fueron comparables a las de evaluadores humanos y redujeron el tiempo de análisis.

2.500	250	100
hipocótilos de Arabidopsis	hipocótilos de Sinapis	plántulas de Brachypodium

ESTE TRABAJO · NAIVE BAYES

Implementación solo en Python, con los canales de color RGB, sin aprendizaje profundo y sin software externo especializado.

La apuesta: menor complejidad computacional, aun a costa de cierta pérdida de exactitud.

¿CÓMO? · METODOLOGÍA

Cinco pasos en Python

1

Leer RGB

Extraer la matriz de color de cada imagen.

2

Anotar

Elegir a mano píxeles y registrar su clase.

3

Entrenar

Ajustar un Gaussian Naive Bayes por especie.

4

Predecir

Clasificar la imagen completa, píxel a píxel.

5

Evaluar

Comparar con la máscara de referencia.

Todo el flujo corre en Python (pandas, NumPy y scikit-learn) dentro de Google Colab.

¿CÓMO? · PASO 1 Y 2

Anotar píxeles a mano

Se eligieron píxeles representativos de cada clase sobre la imagen (vista interactiva con Plotly) y se anotó su valor R, G, B (0–255) y su clase en un Excel por especie, con las columnas **r, g, b, label**.

Las filas nulas o fuera de 0–255 se descartan automáticamente: 5 filas en Brachypodium.

Especie	Total	Fondo	Otras	Hipocótilo
Arabidopsis thaliana	250	50	151	49
Sinapis alba	250	50	150	50
Brachypodium distachyon	245	50	146	49

Píxeles anotados por clase: Fondo (0), Otras estructuras (1) e Hipocótilo / coleóptilo (2).

¿CÓMO? · PASO 3

Gaussian Naive Bayes

Fundamento

Asume que R, G y B siguen distribuciones normales e independientes dentro de cada clase. Calcula la probabilidad de cada clase para el píxel y elige la mayor.

Limitación de diseño

Cada píxel se clasifica de forma aislada: el modelo no ve textura, forma ni vecindad.

```
entrenar y predecir
modelo = GaussianNB()
modelo.fit(X_train, y_train)
pred = modelo.predict(X_test)
```

EN UNA LÍNEA

$$P(\text{clase} \mid r, g, b) \propto P(\text{clase}) \cdot P(r \mid \text{clase}) \cdot P(g \mid \text{clase}) \cdot P(b \mid \text{clase})$$

¿CÓMO? · PASO 3

Un modelo por especie y partición 80/20

3

Modelos específicos

El color de las estructuras cambia mucho entre especies, así que cada una tiene su propio modelo.

80/20

Partición estratificada

Entrenamiento y prueba con random_state=42: 200/50, 200/50 y 196/49 píxeles.

.joblib

Persistencia

Cada modelo entrenado se guarda serializado con joblib para reutilizarlo.

¿CÓMO? · PASO 4

Segmentar la imagen completa

Imágenes procesadas

Arabidopsis
3319 × 3225 · 10,7 M de píxeles

Sinapis
3024 × 4032 · 12,2 M de píxeles

Brachypodium
3024 × 4032 · 12,2 M de píxeles

1 · Aplanar

La imagen RGB pasa a un arreglo de N × 3.

2 · Clasificar por bloques

Lotes de 250.000 píxeles para cuidar la memoria RAM.

3 · Reordenar y colorear

Se recupera el alto × ancho original y se asigna la paleta de tres clases.

¿CÓMO? · PASO 5

Cuatro métricas contra la referencia

Métrica	Pregunta que responde	Fórmula
Precisión	De los píxeles asignados a una clase, ¿cuántos eran realmente de ella?	TP / (TP + FP)
Recall	De los píxeles de una clase, ¿cuántos se identificaron?	TP / (TP + FN)
F1-score	Equilibrio armónico entre precisión y recall (equivale al Dice por clase).	2PR / (P + R)
IoU	¿Cuánto se solapan la región predicha y la de referencia?	TP / (TP + FP + FN)

RESULTADOS · PRUEBA EN PÍXELES ANOTADOS

Cerca del 76 % al 80 % de acierto

76 %

Arabidopsis

exactitud sobre 50 píxeles

76 %

Sinapis

exactitud sobre 50 píxeles

79,6 %

Brachypodium

exactitud sobre 49 píxeles

El fondo se separa bien

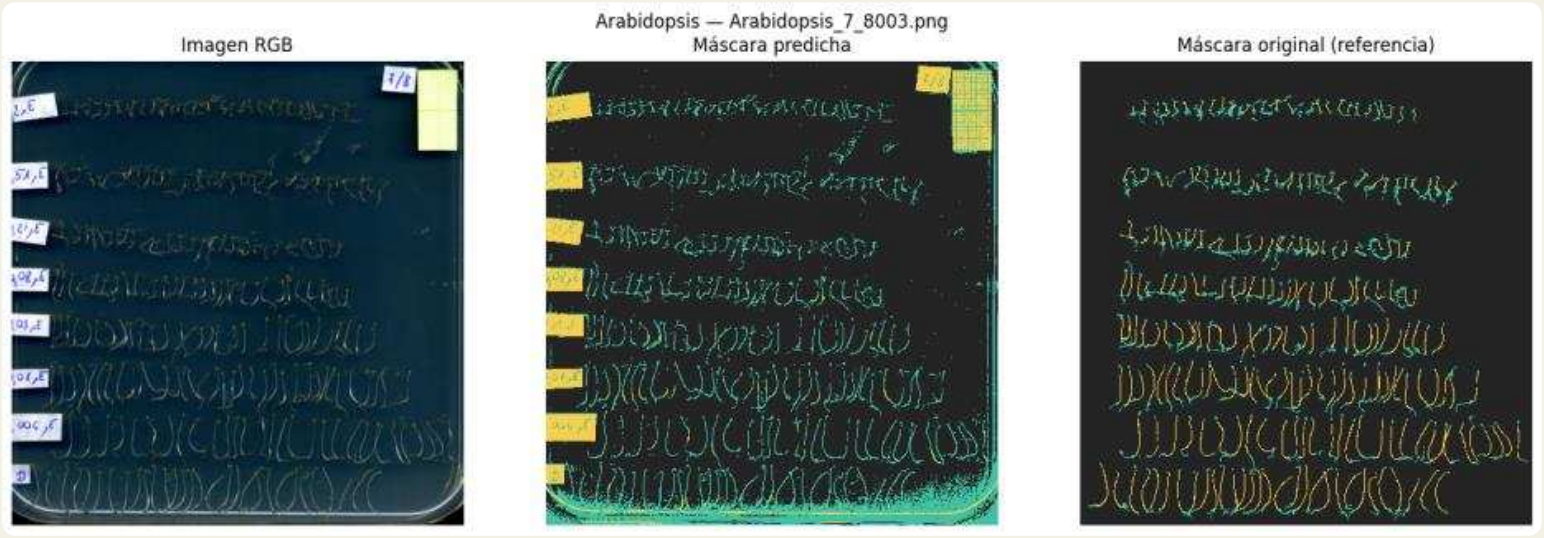
F1 de 1,00 (Arabidopsis), 0,83 (Sinapis) y 0,95 (Brachypodium).

El hipocótilo es la clase más débil

F1 de 0,40 (Arabidopsis), 0,67 (Sinapis) y 0,64 (Brachypodium).

RESULTADOS · ARABIDOPSIS THALIANA

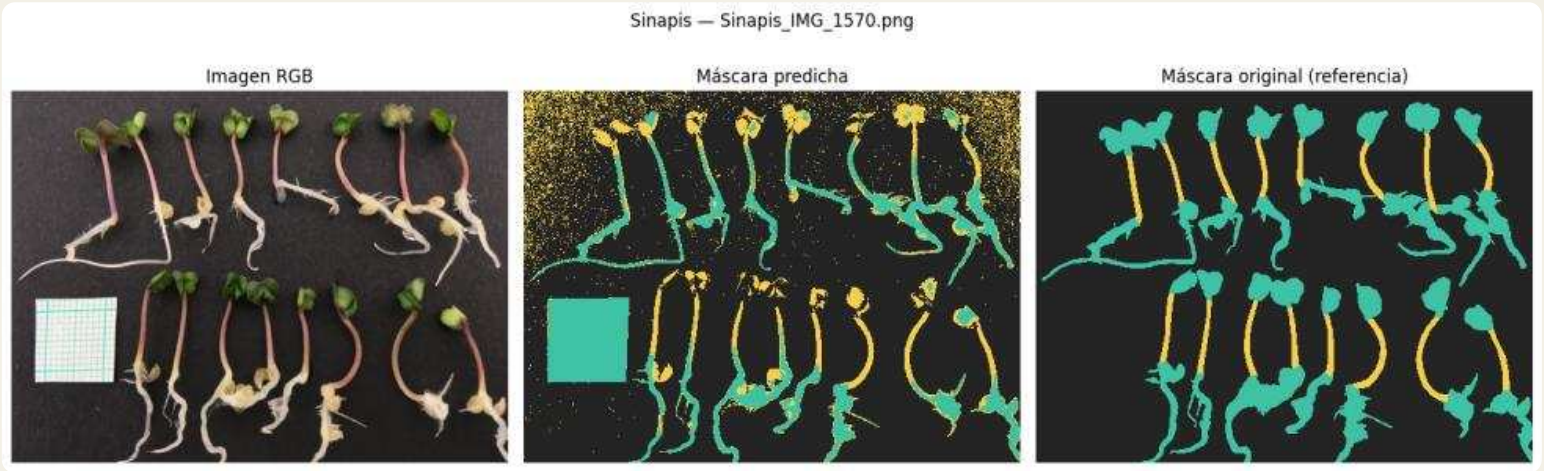
El hipocótilo casi no se detecta



IoU promedio 0,346 **IoU hipocótilo 0,022** **Exactitud de imagen 84,3 %**

RESULTADOS · SINAPIS ALBA

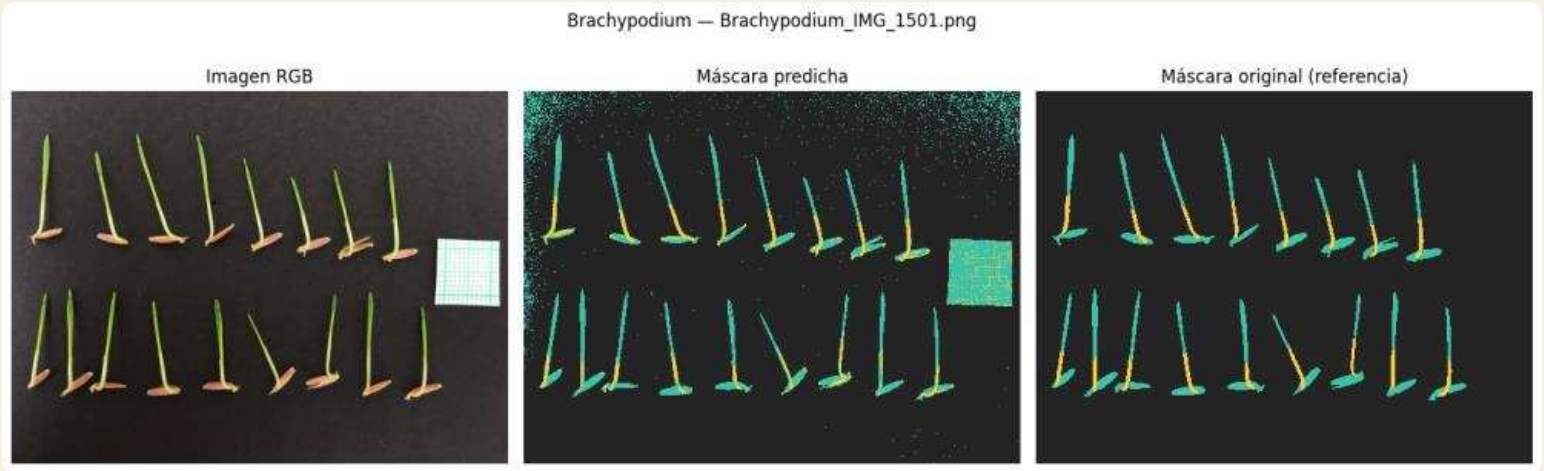
El hipocótilo se confunde con otras estructuras



IoU promedio 0,453 **IoU hipocótilo 0,168** **Exactitud de imagen 83,2 %**

RESULTADOS · BRACHYPODIUM DISTACHYON

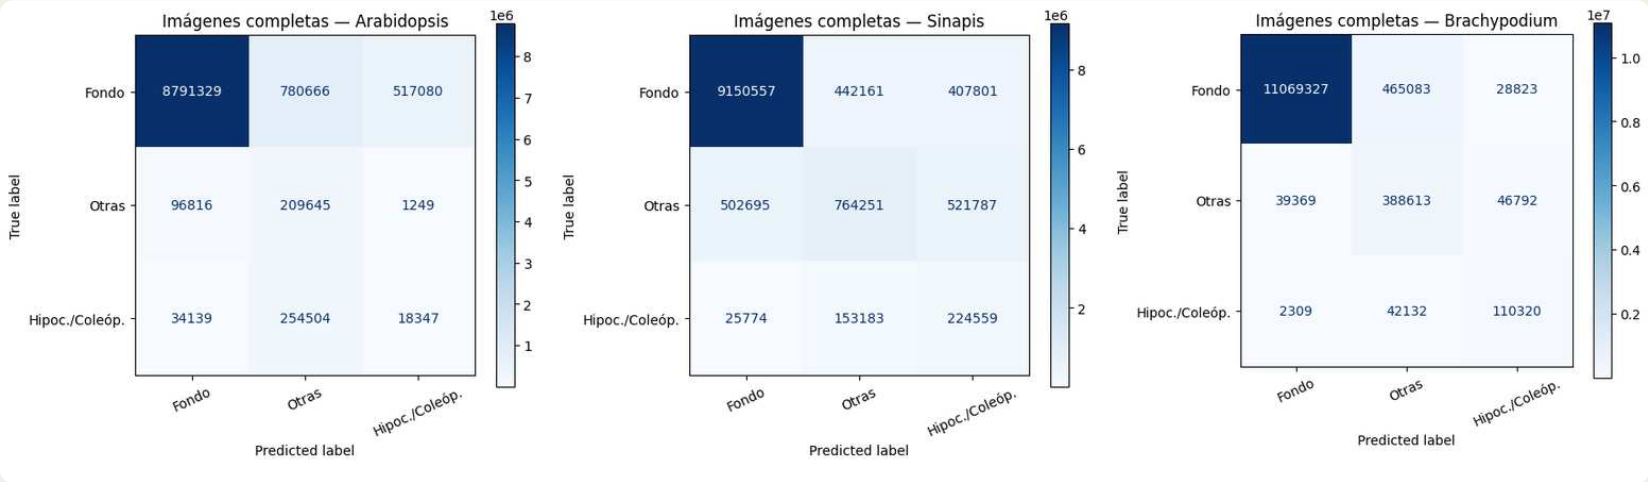
El mejor desempeño de las tres especies



IoU promedio 0,610 **IoU coleóptilo 0,479** **Exactitud de imagen 94,9 %**

RESULTADOS · IMÁGENES COMPLETAS

Dónde se equivoca el modelo

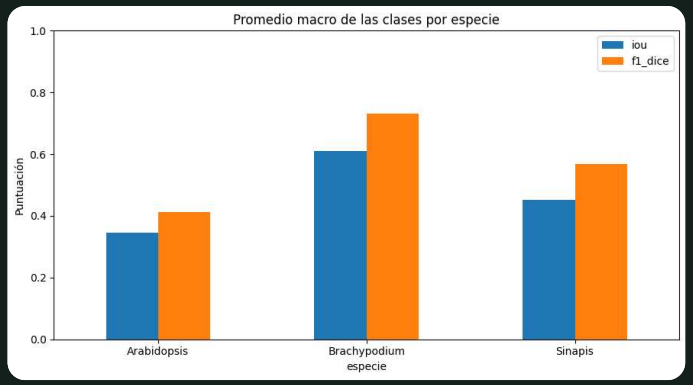


El fondo se acierta en las tres especies. El hipocótilo se confunde sobre todo con «otras estructuras»: en Arabidopsis, 254.504 de sus 306.990 píxeles.

RESULTADOS · PROMEDIO MACRO POR ESPECIE

Brachypodium lidera; Arabidopsis queda última

Especie	Precisión	Recall	F1	IoU
Brachypodium distachyon	0,675	0,830	0,730	0,610
Sinapis alba	0,567	0,633	0,568	0,453
Arabidopsis thaliana	0,396	0,538	0,413	0,346



La segmentación basada solo en RGB no funciona igual en todas las especies: depende del color de sus estructuras, de las sombras y de la similitud con el fondo.

RESULTADOS · IOU POR CLASE

La exactitud global esconde el fallo

Clase	Arabidopsis	Sinapis	Brachypodium
Fondo	0,860	0,869	0,954
Otras estructuras	0,156	0,321	0,396
Hipocótilo / coleóptilo	0,022	0,168	0,479

IoU por clase, imagen completa de cada especie.

ARABIDOPSIS · ADVERTENCIA DE DESBALANCE

84,3 %

de exactitud en la imagen, pero IoU de 0,022 en el hipocótilo.

El fondo domina: 10,09 M de píxeles frente a unos 0,3 M de hipocótilo.

DISCUSIÓN · POR QUÉ FALLA

Tres factores explican la variación

1

Solapamiento cromático

El hipocótilo y las demás estructuras tienen tonalidades parecidas, y solo con RGB no se separan.

2

Sombras e iluminación

Los gradientes de luz y las sombras distorsionan los valores RGB locales.

3

Ausencia de geometría

Cada píxel se clasifica por separado, sin forma ni continuidad de los órganos.

¿PARA QUÉ? · UTILIDAD DEL ENFOQUE

Una línea base ligera para explorar

Sirve para

- Explorar rápido la segmentación de plántulas.
- Separar la planta del fondo en las tres especies.
- Trabajar solo en Python, sin ImageJ ni aprendizaje profundo.
- Tener un punto de comparación frente a métodos más complejos.

Todavía no sirve para

- Delimitar con precisión el hipocótilo: IoU de 0,022 en Arabidopsis y 0,168 en Sinapis.
- Reemplazar a U-Net en la medición automática del hipocótilo.
- Generalizar: solo se evaluó una imagen por especie.

¿PARA QUÉ? · SIGUIENTES PASOS

Limitaciones y trabajo futuro

Limitaciones del estudio

- Una sola imagen representativa por especie.
- Muestreo acotado: unos 250 píxeles anotados a mano.
- Solo el espacio de color RGB.

Trabajo futuro

- Ampliar la muestra de entrenamiento y el número de imágenes.
- Probar espacios de color como HSV o LAB.
- Añadir textura y filtros espaciales.

CONCLUSIÓN · VEREDICTO

Naive Bayes sobre RGB es una alternativa ligera para explorar la segmentación vegetal: aceptable en Brachypodium (IoU 0,610) y muy limitada en el hipocótilo de Arabidopsis (IoU 0,022).

Su capacidad para reproducir las máscaras originales fue variable y requiere validación con más imágenes.

CIERRE

Referencias

Dobos, O., Horvath, P., Nagy, F., Danka, T., & Viczián, A. (2019). A deep learning-based approach for high-throughput hypocotyl phenotyping. *Plant Physiology, 181*(4), 1415–1424. https://doi.org/10.1104/pp.19.00728

Danka, T. *Plant Segmentation* [conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/tivadardanka/plant-segmentation

Imagen de portada: natsci.msu.edu (https://natsci.msu.edu/_assets/images/news/2025/arabisopsis-square.JPG).